

MVP - Pontos de Cultura nos municípios do Rio de Janeiro

Pipeline de dados para organizar, tratar e consultar informações territoriais da Rede Cultura Viva.

Autor	Caíque Cahon
Disciplina	Banco de Dados - Pós-Graduação em Ciência de Dados e Analytics
Instituição	PUC-Rio
Data	23 de setembro de 2026

Pergunta que orientou o trabalho: como os registros de Pontos de Cultura presentes na base da Rede Cultura Viva se distribuem entre os municípios do estado do Rio de Janeiro?

Resumo

Neste MVP, construí um fluxo de dados no Databricks para transformar um arquivo público em uma visão territorial simples e consultável. O trabalho passou pela carga do arquivo, pela preservação dos dados recebidos, pela padronização dos municípios e, por fim, pela criação de uma tabela com a quantidade de registros por município.

O resultado não pretende medir toda a atividade cultural do estado. Ele mostra apenas o que está registrado no arquivo analisado e, por isso, deve ser lido como um retrato da base utilizada.

1. Objetivo e fonte dos dados

Escolhi esse tema porque a distribuição territorial ajuda a perceber onde os registros estão mais concentrados e onde a base apresenta menor presença. A proposta combina uma pergunta de interesse público com práticas de engenharia de dados, mantendo cada transformação visível e reproduzível.

A fonte principal foi o arquivo de Pontos de Cultura disponibilizado pelo Ministério da Cultura no portal da Rede Cultura Viva. Para conferir nomes e códigos municipais, usei como referência a lista oficial de localidades do IBGE.

O portal informa a licença **Creative Commons Atribuição**. Isso permite o compartilhamento e a adaptação dos dados, desde que a fonte seja reconhecida. Neste trabalho, a origem foi citada e a publicação foi limitada aos campos necessários, sem divulgar o arquivo com dados pessoais.

O arquivo original continha campos pessoais, como nome, CPF e contato. Para reduzir o risco de exposição, enviei ao Databricks apenas uma cópia com quatro campos necessários à análise territorial: identificador do registro, estado, município e tipo de agente. O arquivo original não foi publicado no GitHub.

Resumo da estrutura usada na carga

Campo usado na entrada	Tipo recebido	Uso no projeto
Identificador	Texto	Distinguir cada registro
Estado	Texto	Selecionar os registros do RJ
Município	Texto	Validar a localização
Tipo de agente	Texto	Preservar a classificação recebida

2. Coleta e carga

A cópia reduzida foi enviada para um Volume do Unity Catalog. Depois, informei no notebook o caminho do arquivo, o catálogo e o esquema. A primeira validação confirmou que o arquivo estava acessível e que as tabelas seriam gravadas no destino correto.




Figura 1 - Confirmação da localização do arquivo e do destino das tabelas.

3. Camada Bronze: preservar o que foi recebido

A camada Bronze guarda os campos necessários sem alterar seus valores. Essa etapa serve como ponto de partida confiável: se houver dúvida sobre alguma transformação posterior, é possível voltar ao conteúdo recebido e comparar.

Foram lidos 7.257 registros no arquivo completo. Entre eles, 789 estavam marcados com o estado do Rio de Janeiro. O identificador usado no projeto representa o registro da base e não um CPF.




Figura 2 - Execução da camada Bronze e contagem inicial dos registros.

Por que essa etapa importa? Ela separa a entrada original das regras de limpeza. Assim, a análise permanece rastreável e pode ser refeita caso uma regra mude.

4. Camada Silver: verificar e padronizar localidades

Na camada Silver, comparei os nomes dos municípios com a referência do IBGE. A limpeza considerou acentos, diferenças de grafia, registros de distritos e alguns casos que exigiam correção conhecida. Cada linha recebeu uma indicação da regra aplicada, o que evita uma limpeza silenciosa.

Regra aplicada	Quantidade
Nome oficial já reconhecido	622
Padronização de grafia	149
Distrito associado ao município	9
Correção de grafia	7
Localização conflitante	2

Do total de 789 registros marcados como RJ, 787 puderam ser associados a um município oficial. Dois permaneceram como conflito territorial e não entraram na contagem final. Um exemplo é a combinação “Guarulhos (SP)” com estado “RJ”, que não foi atribuída automaticamente a um município fluminense.

← → ↺ ↻ 🔍 dbc-140bbe3-58f1.cloud.databricks.com/editor/notebooks/1782594868643427?displayMode=resultsMode&o=7474647207388723... 🔍 ⭐ 📄 ⚙️ ⚠️ ⋮

databricks 🔍 Search data, notebooks, recents, and more... CTRL + P Verify identity workspace

New Home New File 2026-09-23 09:03:01.py MVP_Pontos_Cultura_RJ_Databricks 2026-09-... × +

File Edit View Run Help Python Results Last edit was 7 minutes ago

Run all Serverless Schedule Comments Share

3. Silver — verificar e padronizar localidades

Usamos a lista oficial do IBGE incorporada neste notebook como referência de nomes e códigos. A coluna `regra_tratamento` permite explicar cada alteração.

Guarulhos (SP) com UF RJ permanece marcado como conflito, sem atribuição automática a município fluminense.

• Command ran successfully

```
> silver: pyspark.sql.connect.dataframe.DataFrame = [id_registro: long, estado_original: string ... 5 more fields]
Distribuição das regras:
+-----+
|regra_tratamento|count|
+-----+
|correcao_grafia  |7     |
|distrito_para_municipio|9     |
|localizacao_conflitante|2     |
|nome_oficial      |622   |
|padronizacao_grafia|149   |
+-----+
```

Registros sem município oficial: 2

4. Gold — resposta pronta para consulta

Figura 3 - Distribuição das regras de tratamento e identificação de dois conflitos.

5. Organização do pipeline

O fluxo foi organizado em três camadas. A Bronze preserva a entrada; a Silver valida e padroniza os municípios; e a Gold entrega uma tabela pronta para consulta. Essa separação deixa claro o papel de cada etapa e facilita a manutenção do projeto.

Todo o processo foi mantido em um único notebook, dividido em blocos executados em ordem. Essa escolha foi suficiente para o tamanho do MVP e tornou a reprodução mais simples. Em um ambiente de produção, as três camadas poderiam ser separadas em tarefas independentes e orquestradas.

Camada	Função no projeto
Bronze	Preservar os campos territoriais recebidos.
Silver	Validar nomes, aplicar regras e registrar conflitos.
Gold	Agrupar os registros válidos por município.

Catálogo de dados transcrito

Tabela	Estrutura
Bronze - Pontos de Cultura	Identificador original: texto; estado original: texto; município original: texto; tipo de agente original: texto.
Silver - Pontos do RJ	Identificador do registro: número inteiro; estado original: texto; município original: texto; tipo de agente: texto; município oficial: texto; código do IBGE: número inteiro; regra de tratamento: texto.
Gold - Pontos por município	Código do IBGE: número inteiro; município oficial: texto; quantidade de registros: número inteiro.

As três tabelas foram salvas em formato Delta no catálogo de trabalho, dentro do esquema padrão. O notebook disponível no GitHub contém a leitura, as verificações, as transformações e os comandos de persistência.




Figura 4 - Catálogo com as três tabelas persistidas e o Volume usado na carga.

6. Camada Gold e principais resultados

A tabela final reuniu 787 registros territoriais validados, distribuídos por 76 municípios. Cada linha representa um município presente no arquivo e sua respectiva quantidade de registros. Municípios ausentes não receberam valor zero, porque a ausência na base não prova que não existam Pontos de Cultura nesses locais.

Município	Registros
Rio de Janeiro	358
Niterói	37
Duque de Caxias	34
Nova Iguaçu	33
São Gonçalo	23
Petrópolis	20
Belford Roxo	16
São João de Meriti	16
Nova Friburgo	13
Volta Redonda	13

O Rio de Janeiro aparece muito acima dos demais municípios, com 358 registros. Esse resultado mostra uma forte concentração no arquivo analisado, mas não permite concluir sozinho que a oferta cultural real esteja concentrada na mesma proporção.




Figura 5 - Resultado da camada Gold com os municípios de maior contagem.

7. Consulta e visualização

Para conferir o resultado fora do notebook, criei uma consulta no editor SQL. Ela seleciona o município e a quantidade de registros, ordena do maior para o menor e limita a visualização aos dez primeiros. A consulta retornou os mesmos valores apresentados pela camada Gold.




Figura 6 - Consulta SQL executada com sucesso e resultado em tabela.

Também gerei um gráfico de barras horizontais. A visualização deixa evidente a diferença entre a capital e os demais municípios. A escala foi mantida sem ajuste artificial para não esconder essa concentração.




Figura 7 - Gráfico com os dez municípios de maior contagem no arquivo.

8. Limitações da análise

Os números representam registros presentes no arquivo consultado e não um censo completo dos Pontos de Cultura. A data de criação de um cadastro também não informa necessariamente quando a atividade cultural começou. Além disso, um município ausente pode estar sem registro na base, e não sem iniciativas culturais.

As duas linhas com localização conflitante foram mantidas na Silver para auditoria, mas ficaram fora da Gold. Essa escolha evita atribuir automaticamente um registro a um município errado. Em uma continuação do trabalho, esses casos poderiam ser revisados com outra fonte ou por validação manual documentada.

9. Reprodutibilidade e entrega

O repositório público reúne o notebook executado, a documentação do projeto e as instruções necessárias para compreender o fluxo. O arquivo original com dados pessoais não foi incluído. A documentação apresenta a pergunta, a fonte, as decisões de tratamento, os resultados e as limitações.

Repositório: github.com/ccahon/mvp-pontos-cultura-rj




Figura 8 - Repositório final com o notebook e a documentação principal.

10. Conclusão

O MVP respondeu à pergunta proposta ao organizar os registros por município e tornar o resultado consultável. O pipeline conseguiu preservar a entrada, documentar as regras de qualidade, separar conflitos e produzir uma tabela final com 787 registros válidos em 76 municípios.

O principal achado foi a grande concentração de registros na capital: 358, contra 37 em Niterói, o segundo município da lista. Esse contraste é útil para orientar novas perguntas, mas deve ser interpretado dentro dos limites da fonte. Uma etapa futura poderia comparar os registros com população municipal, regiões de governo ou indicadores de acesso a equipamentos culturais.

Avaliação do trabalho

Considero que o projeto atende ao objetivo de um MVP porque entrega um caminho completo: parte de um arquivo público, aplica controles de privacidade, cria camadas de dados, registra as decisões de limpeza e apresenta uma consulta final verificável. O ponto mais importante foi não tratar automaticamente os casos duvidosos. Isso reduziu o risco de produzir uma resposta aparentemente precisa, mas territorialmente incorreta.

As principais dificuldades foram preparar uma cópia segura do arquivo, entender a organização entre Volume, catálogo e esquema no Databricks e tratar nomes de localidades que não coincidiam diretamente com a referência oficial. Também foi necessário corrigir a consulta SQL para posicionar o limite de linhas antes do ponto final. Esses ajustes fizeram parte do aprendizado e foram validados antes da entrega.

Resultado final: um fluxo reproduzível, com dados pessoais fora da entrega pública, três camadas organizadas e uma resposta territorial pronta para consulta.

Referências

Ministério da Cultura. Base de Pontos de Cultura da Rede Cultura Viva. Consulta realizada em 22 de setembro de 2026.

Instituto Brasileiro de Geografia e Estatística. API de Localidades, referência de municípios e códigos oficiais.

Databricks. Ambiente utilizado para armazenamento, processamento, catálogo, consulta SQL e visualização.